


SVM MARGIN

GRZEGORZ BORKOWSKI

Treść zadania

Wygenerujemy rozkład punktów podobny jak na powyższym obrazku. Dla takiego rozkładu zbadajmy jak będą się zachowywały w zależności od wybranego współczynnika C następujące wartości (do przetestowania rozsądny zakres i ilość współczynników C - tak aby pokazać trend na wykresie): * jaka jest szerokość marginesu * jaki % punktów znalazł się po "niewłaściwej" stronie płaszczyzny dzielącej klasy. Dokonajmy obliczeń dla zwykłego SVM, SVM z kernelem wielomianowym stopnia trzeciego i SVM z kernelem RBF (uważajmy na współczynnik γ , w szczególności nie zapomnijmy sprawdzić efektów dla $\gamma < 1$). Zwizualizujmy też efekty działania poprzez odpowiednie pomalowanie płaszczyzny (tak jak robiliśmy to przy metodzie k-NN).




Rysunek 1: Zbiór testowy


Rozwiązanie

Korzystałem z SVM liniowego oraz SVM z kernelem wielomianowym stopnia 3 i kernelem rbf. Dla każdego z tych klasyfikatorów wybierałem parametr C ze zbioru $\{0.001, 0.01, 0.1, 1\}$ oraz dla SVM z kernelem nieliniowym dodatkowo parametr γ ze zbioru $\{0.01, 0.1, 1\}$. Następnie wyznaczałem procent punktów znajdujących się po odpowiedniej stronie “płaszczyzny” i szerokość marginesu.


Wyniki i część z granic decyzyjnych przedstawiona na poniższych wykresach.




Rysunek 2: Klasyfikator SVM liniowy, szerokość marginesu w zależności od parametrów (C , γ)




Rysunek 3: Klasyfikator SVM liniowy, skuteczność klasyfikatora w zależności od parametrów (C, gamma)




Rysunek 4: Klasyfikator SVM kernel wielomianowy, margines w zależności od parametrów (C , γ)




Rysunek 5: Klasyfikator SVM kernel wielomianowy, skuteczność w zależności od parametrów (C , γ)




Rysunek 6: Klasyfikator SVM kernel rbf, margines w zależności od parametrów (C, gamma)




Rysunek 7: Klasyfikator SVM kernel rbf, skuteczność w zależności od parametrów (C, gamma)




Rysunek 8: Granica decyzyjna SVM liniowy, $C = \gamma = 0.1$




Rysunek 9: Granica decyzyjna SVM liniowy, $C = 0.01$, $\gamma = 0.1$



Rysunek 10: Granica decyzyjna SVM kernel wielomianowy, $C=\gamma=1$



Rysunek 11: Granica decyzyjna SVM kernel rbf, $C=\gamma=0.1$



Rysunek 12: Granica decyzyjna SVM kernel rbf, $C=0.1$, $\gamma=1$

Wnioski

- (1) Dla każdego z kerneli widzimy, że im większy margines, tym mniejsza skuteczność klasyfikatora. Klasyfikatory z parametrem $C = 0.001$, mają największy margines i najmniejszą skuteczność.
- (2) Dobór rodzaju kernela i parametrów C i γ jest bardzo istotny i silnie zależy od rodzaju danych które chcemy klasyfikować. Złe decyzje mogą prowadzić do miernych rezultatów klasyfikatora (lepsze parametry C i γ powodowały, że skuteczność klasyfikatora rosła o 30 punktów procentowych!)
- (3) Parametr γ nie miał wpływu na szerokość marginesu, jedynie na skuteczność klasyfikatora.